

# Informe Teórico Práctico 1

## Limpieza, EDA y Transformación

SI3015 - Fundamentos de Aprendizaje Automático

2026

### 1. Informe:

Descargar uno de estos dos datasets:

Link dataset de películas

Link dataset del Titanic

**Nota:** también puede probar con un conjunto de datos propio que no esté limpio y que sea de una de las siguientes fuentes de datasets:

- <https://www.kaggle.com>
- <https://ieee-dataport.org/datasets>
- <https://mlcontests.com/>

#### 1.1. Limpieza

Realizar las siguientes actividades sobre el conjunto de datos:

- Cargue el conjunto de datos.
- Ejecute comandos de inspección rápida.
- Realice y verifique manejo de valores faltantes (NaNs).
- Realice manipulación de filas y columnas.
- Realice limpieza de texto y manejo de duplicados.
- Verifique la consistencia y validación lógica del conjunto de datos.
- Realice transformación de tipos y filtrado si es necesario.
- Realice y verifique operaciones de agregación y agrupamiento.

- Redacte, donde corresponda, procesos realizados que consideren relevantes.
- Redactar conclusiones interesantes de acuerdo a la limpieza de datos.

## 1.2. EDA y transformación de columnas

- Realice Medidas de Tendencia Central.
- Realice Medidas de Dispersión.
- Realice Medidas de Posición y elimine outliers si es necesario.
- Realice Histogramas para analizar la distribución de las columnas.
- Realice Gráficos de Dispersión entre dos columnas para analizar la relación entre las dos.
- Una vez realizada la exploración de datos, realice distintas transformaciones de columnas:
  - One Hot Encoding, Label Encoding, Binary Encoding.
  - Correlacione columnas para determinar si es necesario eliminar algunas de ellas.
  - Escale las columnas con Min-Max Scaling o StandardScaler.
  - Realice transformación logarítmica, de ser necesario.
- Redacte, donde corresponda, procesos realizados que consideren relevantes.
- Redactar conclusiones interesantes de acuerdo a la exploración de datos.

## 1.3. Comparación entre limpieza mínima y máxima

### 1.3.1. Limpieza mínima

-Realizar la mínima limpieza posible para que pueda ejecutarse sin errores de compilación un algoritmo de ML. Recuerde usar `aplicarModeloML.ipynb` para aplicar un algoritmo de ML.

-Guarde el desempeño obtenido.

### 1.3.2. Limpieza máxima

-Realizar la máxima limpieza posible para aplicar el mismo algoritmo de ML usando en la limpieza mínima. Recuerde usar `aplicarModeloML.ipynb` para aplicar un algoritmo de ML.

-Guarde el desempeño obtenido. Este desempeño debe ser ligeramente mejor que el desempeño de la limpieza mínima.

-Redactar conclusiones interesantes respecto a esta comparación.

**Nota:** el algoritmos escogido para la limpieza mínima y máxima deben ser iguales y conservar los mismos parámetros de configuración.

## Tener en cuenta:

- Cerciorese de realizar la mayor limpieza, exploración y transformación posible del conjunto de datos. Recuerde que un conjunto de datos suficientemente limpio y transformado aumenta significativamente la probabilidad de obtener muy buenos resultados al aplicar el modelo de aprendizaje automático.
- Recuerde basarse en las presentaciones y ejemplos de clase para realizar las actividades de este informe.
- La entrega se puede realizar en grupos de máximo 3 personas. Basta con que uno de los tres integrantes realice el envío.
- **Entregable:** dos archivos separados, un \*.ipynb y un pdf del \*.ipynb.